

Table of Contents

3-D Datenrekonstruktion mit generative Adversarial Networks	2
<i>Andreas Wiegand</i>	
1 Einleitung	2
1.1 Objectives	3
1.2 Outline	4
2 Grundlagen und ähnliche Arbeiten	4
2.1 Künstliche Neuronale Netzwerke	5
2.1.1 Ziel-Funktion	8
2.1.2 Backpropagation Algorithmus	8
2.1.3 Momentum	9
2.1.4 Regularization	10
2.1.5 Batch Normalisation	11
2.2 Datenformat Punktwolken	13
2.2.1 Datenaufnahme von Tabakpflanzen	14
2.2.2 Das Problem mit 3D-Data bei Machine Learning Ansätzen	15
2.3 Convolution Neural Networks	15
2.4 Autoencoder	18
2.5 Generative Adversarial Network	21
2.5.1 Probleme mit Generative Adversarial Networks	23
2.5.2 Lösungsansätze für Generative Adversarial Networks	
Probleme	24
2.6 Conditional-GAN	26
2.7 3D-GAN	26
2.8 Rekonstruktion von Daten	28
3 Methoden	29
3.1 Datensatz 1. Versuchsaufbau	29
3.2 Datensatz 2. Versuchsaufbau	31
3.3 Trainingsaufbau 1 - GAN	31
3.4 Trainingsaufbau 2 - CGAN für Punktwolkenrekunstroktion	32
4 Evaluation und Ergebnisse	33
4.1 Ergebnisse - Versuchsaufbau 1	33
4.2 Ergebnisse - Versuchsaufbau 2	33
5 Zusammenfassung und Diskussion	40
Literatur	48

C-GAN Conditional Adversarial Networks

EMD Earth Mover Distanze

KNN Künstliches Neuronales Netzwerk

3-D Datenrekonstruktion mit generative Adversarial Networks

Andreas Wiegand

Master These in künstlicher Intelligenz

Zusammenfassung. Generative Adversarial Network(GAN) ist ein künstliches neuronales Netzwerk(ANN) aus dem Bereich der generativen Modelle. Die Aufgabe des GANs ist es, die Wahrscheinlichkeitsverteilung von Trainingsdaten zu erlernen und dadurch anschließend neue Samples aus dieser Wahrscheinlichkeitsverteilung zu generieren. Man erhofft sich, den hohen Datenaufwand beim trainieren von ANN zu umgehen und durch GANs neue Trainingsdaten zu generieren. Ziel dieser Arbeit ist es das Konzept von GANs auf 3D-Scans von Tabakblättern anzuwenden um die Wahrscheinlichkeitsverteilung von 3D-Daten zu erlernen. Ein weiteres Ziel ist es heraus zu finden ob mit Hilfe von GANs es möglich ist 3D-Daten welche beispielsweise beim Scannen unvollständig sind ergänzen zu können. Im Folgenden wird auf die Theorie von GANs eingegangen, wie deren Aufbau und deren zugrunde liegendes mathematische Modell. Anschließend werden die Methoden des Experimentes präsentiert sowie die Ergebnisse diskutiert.

1 Einleitung

Um genauere Prognosen über Erntemenge und frühzeitiger Erkennung von Krankheiten zu treffen werden 3D-Scan verfahren eingesetzt welche Pflanzen scannen und damit 3D-Daten liefern welche zur weiterverarbeitung von Machine-Learning Ansätzen benötigt werden. [EVLUT BILD EINBAUEN UND GENAUER AUF SCANVERFAHRENE INGEHEN]. Jedoch sind diese Scanverfahren wie jede Informationsübertragung mit sogenannten rauschen verbunden das heißt die Information vom Empfänger zum Sender wird verändert und behält nicht die ursprünglichen Inhalt. Beispiele dafür waren ein Blatt verdeckt ein anderes Blatt und lässt die Sensoren des Scanner nicht zu das unter trunder liegende Blatt zu erfassen. Um nun diesen Verlust von Daten zu verhindert muss geprüft werden ob die Möglichkeit besteht diese Daten zu reparieren in dem sie ergänzt werden. In dieser Arbeit wird ein Ansatz überprüft welcher es Möglich machen kann dieses Verhalten zu erhalten. Ein Ansatz der dafür Verwendet werden kann ist Deep Learning bei dem man das Deep Learning Modell den unterschied zwischen Reparierten und nicht reparierten Daten erlernt kann es rückschlüsse zeihen und selber Daten reparieren.

Deep learning, however, gained much popularity across many academic disciplines in recent years and has been used in computer vision successfully to

produce state-of-the-art results for various tasks. It is described as the application of multiple processing layers to produce multiple levels of representation. It is therefore capable of learning higher level representations of raw data, that can be used for the intended task, e.g. classification of an image. The most common realization are artificial neural networks (ANN) and especially convolutional neural networks (CNN) for processing data with a grid-like topology, e.g. images. Several publications have shown the effectiveness of CNNs for instance segmentation of plant leaves on images (e.g. Ren and Zemel, 2016). But there is a lack of research in applying deep neural networks to 3D representations of plants.

In den letzten Jahren haben sich im Deep Learning Bereich besonders die discriminativen Modelle hervorgehoben, welche Input Daten wie Bilder, Audio oder Text Daten zu bestimmte Klassen zuordnen. Der Grund für das steigende Interesse liegt in der niedrigen Fehlerrate bei discriminativen Aufgaben, im Vergleich zu anderen Maschine Learning Ansätzen, wie Decision Trees oder Markov Chains (Goodfellow, Bengio, Courville, & Bengio, 2016). Die Modelle lernen eine Funktion welche Input Daten X auf ein Klassen Label Y abbildet. Die Modelle werden dabei von ANN repräsentiert. Man kann auch sagen das Modell lernt die bedingte Wahrscheinlichkeitsverteilung $P(Y|X)$ (Ng & Jordan, 2002). Generative Modelle haben die Aufgabe die Wahrscheinlichkeitsverteilung von Trainingsdaten zu erlernen. Es lernt eine multivariate Verteilung $P(X, Y)$, was dank der Bayes Regel auch zu $P(Y|X)$ umgeformt werden kann und somit kann das Modell auch für discriminativen Aufgaben herangezogen werden. Gleichzeitig können aber neue (x,y) Paare erzeugt werden, was zu dem Ergebnis von neuen Datensätzen führt welche nicht Teil der Trainingssample sind (Ng & Jordan, 2002). In diesem Paper wird speziell auf GAN, aus der Vielzahl von generativen Modellen eingegangen. Diese wurden von Goodfellow (Goodfellow et al., 2014) entwickelt und ebneten den Weg für Variationen, welche auf der Grundidee von GANs aufbauen. 2017 wurden alleine 227 neue Paper zu diesem Thema vorgestellt. Ein Grund weshalb GAN an Popularität gewinnt ist der, dass neuronale Netzwerke mit Zunahme der Trainingsdatenanzahl eine Erhöhung der Performance für die sie Trainiert werden zeigen. Was bedeutet, dass sich mit Zunahme der Datenanzahl die Chance auf eine bessere Performance der Neuronalen Netzwerke ergibt (Halevy, Norvig, & Pereira, 2009). An diesem Punkt erhofft man sich durch GANS mehr qualitative Daten zu erzeugen und somit das Trainingsergebnis zu discriminativen Modelle zu verbessern.

1.1 Objectives

In den letzten Jahren haben sich im Deep Learning Bereich besonders die discriminativen Modelle hervorgehoben, welche Input Daten wie Bilder, Audio oder Text Daten zu bestimmte Klassen zuordnen. Der Grund für das steigende Interesse liegt in der niedrigen Fehlerrate bei discriminativen Aufgaben, im Vergleich zu anderen Maschine Learning Ansätzen, wie Decision Trees oder Markov Chains (Goodfellow et al., 2016). Die Modelle lernen eine Funktion welche Input Daten X auf ein Klassen Label Y abbildet. Die Modelle werden dabei von ANN

repräsentiert. Man kann auch sagen das Model lernt die bedingte Wahrscheinlichkeitsverteilung $P(Y|X)$ (Ng & Jordan, 2002). Generative Modelle haben die Aufgabe die Wahrscheinlichkeitsverteilung von Trainingsdatendaten zu erlernen. Es lernt eine multivariate Verteilung $P(X, Y)$, was dank der Bayes Regel auch zu $P(Y|X)$ umgeformt werden kann und somit kann das Modell auch für discriminativen Aufgaben herangezogen werden. Gleichzeitig können aber neue (x, y) Paare erzeugt werden, was zu dem Ergebnis von neuen Datensätzen führt welche nicht Teil der Trainingssample sind (Ng & Jordan, 2002). In diesem Paper wird speziell auf GAN, aus der Vielzahl von generativen Modellen eingegangen. Diese wurden von Goodfellow (Goodfellow et al., 2014) entwickelt und ebneten den Weg für Variationen, welche auf der Grundidee von GANs aufbauen. 2017 wurden alleine 227 neue Paper zu diesem Thema vorgestellt. Ein Grund weshalb GAN an Popularität gewinnt ist der, dass neuronale Netzwerke mit Zunahme der Trainingsdatenanzahl eine Erhöhung der Performance für die sie Trainiert werden zeigen. Was bedeutet, dass sich mit Zunahme der Datenanzahl die Chance auf eine bessere Performance der Neuronalen Netzwerke ergibt (Halevy et al., 2009). An diesem Punkt erhofft man sich durch GANS mehr qualitative Daten zu erzeugen und somit das Trainingsergebnis zu discriminativen Modelle zu verbessern.

1.2 Outline

Diese Arbeit ist folgender Maßen strukturiert. In Kapitel 2 "Grundlagen und ähnliche Arbeiten" werden theoretische Grundlagen welche für diese Arbeit benötigt wird genauer beleuchtet. Außerdem sollen vorangegeganngen Arbeiten welche einfluß auf diese Ausüben vorgestellt werden um zu veranschaulichen aus welchen Gründen diese Funktionieren kann.

Kapitel 3 - stellt die Arbeit an sich vor. Welche Methoden gewählt wurden ob diese zu Entwickeln und Auszuführen. Die Trainingsdaten werden vorgestellt und Modelle aufgezeigt.

Kapitel 4 - Gibts ausführliche Angaben über die Ergebnisse von den Experimenten und evaluiert sie für ihre Aussagekraft.

Kapitel 5 - Gibt eine Zusammenfassung über die Arbeit und wird sie kritisch Diskutieren. Desweiteren wird ein Ausblick erstellt inwiefern das Ergebnis für zukünftige Arbeiten von relevanz ist.

2 Grundlagen und ähnliche Arbeiten

Im folgenden Kapitel wird auf theoretische Grundlagen eingegangen, welche zum Verständnis für Arbeit benötigt werden. Zunächst werden generative Modelle im Allgemeinen vorgestellt, welche den Grundgedanken der Datengeneration für

GANs aufzeigen und mit deren Hilfe es möglich gemacht werden soll unkenntliche beziehungsweise beschädigte Modelle von Objekten wieder herzustellen. Diese Theorie baut zunächst auf die Datenstruktur von künstlichen Neuronalen Netzwerken auf, welche durch verschiedene Modelle dargestellt werden können. Im Kapitel Conditional-GAN und 3D-GAN werden die theoretischen Grundbausteine der vorherigen Themen vertieft und bilden den Grundstein für das in dieser Arbeit vorgestellte verfahren zur 3D-Datenrekonstruktion von 3D-Modellen aus Tabakblättern.

2.1 Künstliche Neuronale Netzwerke

Künstliche Neuronale Netzwerke(KNN) ist eine Datenstruktur welche von biologischen neuronalen Netzen wie sie bei Lebewesen vorkommen inspiriert sind. KNN haben das Ziel ein Funktion f^* zu approximieren. Dabei werden Parameter Θ eines Models so angepasst, um die Abbildung von $y = f(x; \Theta)$ zu approximieren. Die Modelle werden auch als feedforward Neuronale Netzwerke betitelt weil der Informationsfluss des Models von Input zu Output fließt und keine Rekursion von Output zu Input statt findet. Diese Approximation wird durch Machine Learning Ansätzen erlernt man spricht auch von einen Optimierungsproblem. KNN können aus mehreren Schichten sogenannten Hidden Layer n besteht welche als $f^{(n)}$ dargestellt werden wobei $n \geq 1$ sein muss. Ein 2-Layer KNN ist dann definiert durch $f(x) = f^{(2)}(f^{(1)}(x))$. Man spricht auch von Fully-Connected-Layer. Es gibt einen Input Layer welche den Input in das Netzwerk aufnimmt (Goodfellow et al., 2016). Ein ANN mit mehr als nur 1 Layer und wird dies mit Maschine Learning trainiert spricht man auch von Deep Learning. Im vorherigen Beispiel ist dies $f^{(1)}$ und der letzte Layer des Netzwerkes wird Output Layer genannt. Im vorherigen Beispiel ist das $f^{(2)}$. In Abb. 1 sind ein KNN exemplarisch dargestellt. Es soll die Konnektivität der einzelnen Layer veranschaulichen und den Informationsfluss von Input zu Output.




Abb. 1. Künstliches Neuronales Netzwerk

Jeder Layer besteht aus künstliche Neuronen diese haben ihren Namensgebung von aus der Natur stammende Neuron in Gehirnen von Lebewesen. Neuronen sind die Bausteine aus denen die Gehirne von Lebewesen, wie Fische, Vögel, Säugetiere zusammen gesetzt sind. Neuronen oder auch Nervenzellen bestehen in eine Zellkern der Zentrum der Zelle um sie herum sind Dendriten. Neuronen sind untereinander mit den Axon verbunden, diese haben an den enden Synapsen welche die grenze von Axon zur Nervenzelle einen Spalt bilden. Dieser Spalt kann überwunden werden indem von der Synapse Botenstoffe abgesendet werden welche sich dann an Rezeptor der gegenüberliegenden Synapse anhaften. Diese Übertragung findet statt wenn an der Synapse ein bestimmter Schwellenwert überschritten hat wurde von elektrischen reizen welche die Zelle abfeuert lässt. Künstliche Neuronen haben diese Schwellenwert durch sogenannte Gewichte w_{ij} diese sind auf den Verbindungen zwischen den Neuronen in den unterschiedlichen Layern im ANN. Dabei steht i für die Layersposition im Netzwerk und j für das jeweilige Neuron im Netzwerk.




Abb. 2. künstliches Neuron

Jeder Layer eines KNN besteht aus mehreren Neuronen. Ein Neuron θ kann mehrere Input X_n erhalten und produziert einen Output ω . Die Berechnungen welche von den Neuron durchgeführt wird ist zunächst jeden Input X_n mit einem Gewicht w_{ij} zu multiplizieren. Anschließend wird die Summe von $x \cdot w$ gebildet. Das Ergebnis wird dann in eine Aktivierungsfunktion λ gegeben. Ein Neuron ist definiert durch:

$$y_k = \lambda(\sum_{j=0}^m (w_{kj} + x_j) + b_k)$$

Die Aufgabe der Aktivierungsfunktion λ ist es eine nicht lineare Transformation des Inputs zu erzeugen. Damit kann das KNN nicht lineare Funktionen abbilden und somit komplexere Aufgaben lösen. Es gibt unterschiedliche Aktivierungsfunktionen im folgenden werden einige aufgezählt:

Sigmoid-Funktion $\sigma(x) = \frac{1}{1 + \exp(-x)}$

Softmax-Funktion $\zeta(x)_j = \frac{e^{x_j}}{\sum_{k=1}^K e^{x_k}}$

Rectified Linear Unit (ReLU): $f(x) = \max(0, x)$

Leaky Rectified Linear Unit(Leaky Relu): $f(x) = \begin{cases} x & \text{if } x > 0 \\ 0.01x & \text{sonst} \end{cases}$

Der Funktionsplot von Sigmoid Funktion kann in Abb.11 entnommen werden. Diese veranschaulichen den Wertebereich welcher von den Aktivierungsfunktion angenommen werden kann und ihren Verlauf.




Abb. 3. Sigmoid Funktion

2.1.1 Ziel-Funktion

Die Ziel-Funktion oder auch Loss-Funktion genannt $J(\theta)$ muss Differenzierbar sein. Das heißt unsere Funktion $f: D \rightarrow R$ ist differenzierbar an der Stelle x_0 . Wenn nun $f': x \rightarrow f(x)$ an jeden Punkt x^n ableitbar ist, ist f differenzierbar. Die Aufgabe der Ziel-Funktion ist es zu messen wie gut unsere Modell θ $f^*(x)$ approximiert. Man verwendet auch gerne den Begriff Kosten, also wie viel Kosten unser Modell erzeugt bei den lösen der zugewiesenen Aufgabe. Die Wahl welche Funktion gewählt wird ergibt sich aus der Aufgabe des KNN. Diese kann beispielsweise für Klassifikation oder Regression Aufgaben hergenommen werden. Bei Regression soll eine kontinuierlicher Variablen von Θ als Output generiert werden wohin gegen bei Klassifikationsproblemen der Output Klassen-Labels darstellen (Goodfellow et al., 2016). Es gibt verschiedene Ziel Funktionen im folgenden wird die Cross Entropy Loss Function vorgestellt (Golik, Doetsch, & Ney, 2013). Diese kann verwendet werden um Beispielsweise Klassifikationsprobleme zu lösen. Diese ist definiert als:

$$\hat{q}(c | x) = \arg \min_{q(c|x)} \left\{ - \sum_n \log q(c_n | x_n) \right\}$$

Wobei $x_n: n=1, \dots, N$ die Trainingsdaten sind ist und $c_n: n=1, \dots, N$ die mögliche Klassen. Der Output ist die Wahrscheinlichkeit zwischen 0 und 1 ob $x_i \in$ der bestimmten Klasse enthalten ist. Auch kann sie hergenommen um zu messen wie hoch die Differenz zwischen zwei Wahrscheinlichkeitsverteilungen ist.

2.1.2 Backpropagation Algorithmus

Um nun KNNs zu trainieren und den gewünschten Output y zu generieren wird der Backpropagation Algorithmus benutzt werden dieser zählt zu den Optimierungs Algorithmen für KNN. Er konnte zeigen das dieser Algorithmus schneller und effizienter auf Neuronalen Netzwerken arbeitet als andere Optimierungsalgorithmen vor ihm. Das mathematische Zugrundeliegende Konzept ist ein Optimierungsproblem der die Partitiellen Ableitung von $\frac{\partial Z}{\partial w}$, wobei Z die Zielfunktion und w die Gewichte im zu optimierenden Neuronalen Netzwerk sind. Für eine Funktion $f(x) = y$ ist die Ableitung definiert als $f'(x)$ oder $\frac{dy}{dx}$ und gibt die Steigung der Funktion an Punkt x an. Durch die Steigung an Punkt x ist man nun in der Lage einer Änderung von der Ableitung x dahin gehen optimieren (Goodfellow et al., 2016). Dieses Verfahren hilft dabei das KNN dahingehen zu optimieren den gewünschten Output y zu erlangen. Dieses Ziel wird durch die Ziel-Funktion einen KNN beschrieben. Das Verfahren wird in 4 veranschaulicht.

Wenn nun $f'(x) = 0$ haben wir keinerlei Information über die Steigung erreicht. Dies ist aber kein Indiz dafür sein das f ein Optimum erreicht hat. Es könnten wie in Abbildung 5 unten dargestellt ein lokales Minimum sein das heißt das wir nur an diesen Punkt ein Minimum erreicht haben aber im Funktionsverlauf ein noch niedrigeres Minimum vorhanden ist. Oder einen Sattelpunkt welche




Abb. 4. LossFunktion

ein Übergang zu einem Anstieg der Funktion bildet. Ist nun die Funktion f definiert als $f: \mathbb{R}^n \rightarrow \mathbb{R}$ und hat als Input mehrere Variablen. Die partielle Ableitung $\frac{\partial f(x)}{\partial x_i}$ zeigt an, wie sehr sich $f(x)$ ändert, wenn wir x_i ändern. Der Gradient $\nabla_x f(x)$ ist ein Vektor, der alle partiellen Ableitungen von f enthält. Nun kann man f optimieren, indem man in die Richtung des Gradienten geht, welche negativ ist. Dieses Verfahren wird Gradient Descent genannt (Goodfellow et al., 2016).




Abb. 5. Minimum Maximum Saddle Point

2.1.3 Momentum

Momentum hat das Ziel, das Gradientenverfahren des Backpropagation Algorithmus 2.1.2 zu beschleunigen, um ein effizienteres Ergebnis herbei zu führen und ein schnelleres Lernen erzielt zu erreichen. Definiert ist dieses durch:

$$v_{t+1} = \mu v_t - \epsilon \nabla f(\theta_t) \theta_{t+1} = \theta_t + v_{t+1}$$

wobei $\epsilon > 0$ die Lernrate ist und $\mu \in [0,1]$ das Momentum ist und $\nabla f(\theta_t)$ der Gradient von θ_t ist. Je größer das Momentum, desto schneller bewegt sich der

Gradient abwärts. Da am Anfang einer Lernphase der Gradient üblicherweise hoch ist empfiehlt sich zunächst mit einem niedrigen Momentum zu arbeiten da sonst die Gefahr besteht über das globale Optimum hinüber zuschießen. Wenn nun das Training stagniert welches aus Gründen der Aufbau der Loss-Funktion zurückzuführen ist das zur Nähe des globalen Optimums flache Täler entstehen welche das Training verlangsamen und es zu keiner Verbesserung kommt, kann man durch Momentum erzwingen größere Gradienten Sprünge einzugehen je länger das Training voran schreitet. Und sich somit schneller zu einem globalen Optimum zu bewegen oder aber aus einem lokalen Optimum hinaus Richtung eines globalen Optimums (Sutskever, Martens, Dahl, & Hinton, 2013).

2.1.4 Regularization

Ein Problem was alle Machine Learning Anwendungen teilen ist das Problem wenn der Trainingsalgorithmus ein gutes Trainingsergebnis erzielt aber dann auf den Testdatensatz ein schlechtes Ergebnis erlangt dies wird Overfitting genannt. Es gibt einige Möglichkeiten welche eingesetzt werden können welche dann aber auch das Trainingsergebnis verschlechtern. Man spricht davon das diese Versuchen zu Regularisieren.

Data Argumentation

Je mehr Daten beim Training verwendet werden desto mehr kann generalisiert werden. Data Argumentation heißt das man mehr Datensätze erstellt. Dies kann durch eine Veränderung der Trainingsdatensätze im Allgemeinen sein, wenn man beispielsweise 3D-Punktwolken rotiert um diese mehrfach zu nutzen. Eine weitere Möglichkeit ist es bestimmte Datenpunkte in einen Datensatz ändert indem man ein Objekt welches auf einem Bild dargestellt wird verkleinert oder vergrößert (Goodfellow et al., 2016).

Dropout

Bei Dropout wird während des Lernprozesses ein gewisser Prozentsatz der Neuronen in jeder Layer nicht verwendet. Dies zwingt das Netzwerk was sonst auf die Abhängigkeiten zwischen den Neuronen lernt eine mehr generalisierte Lösung zu finden (Srivastava, Hinton, Krizhevsky, Sutskever, & Salakhutdinov, 2014).

L2-Regularization

Dabei wird das Gewicht des Neurons während des Trainings nahe zu seinen Ursprung, das heißt den Wert seiner Initialisierung gedrängt. Dies passiert indem ein Regularisierungswert $\Omega = \frac{1}{2}||w||_2^2$ an die Zielfunktion gehängt wird. Dieses sorgt dafür das während dem Training der Gewichtsvektor welche durch das Gradienten Verfahren ermittelt wird schrumpft dieses sorgt für eine höhere Varianz während des Trainings was wiederum das ANN dazu

zwingt mehr zu generalisieren (Goodfellow et al., 2016).

2.1.5 Batch Normalisation

Wie in Kapitel 2.1.2 gezeigt, das stochastischen Gradienten Verfahren Vorteile gegenüber des normalen Gradienten Ermittlung beim Training von KNN. Dadurch das der Input in jeden Layer abhängig von den vorherigen Layern ist können Änderungen von Werten in frühen Layern des KNN große Auswirkungen in tieferen Layern im Netzwerk haben. Dadurch resultiert das in Trainingsabläufen die Verteilung der Gewichte in den jeweiligen Layern verlangsamt wird. Batchnormalization soll die Werteänderung von Gewichten verringern. Dieses Problem wird auch Covariance Shift genannt. Um dies zu verhindern zeigten Sergey Ioffe und Christian Szegedy (Ioffe & Szegedy, 2015) eine Methode welche Batch Normalisation genannt wird. Je mehr Layer das Netzwerk hat desto stärker ist der Covariance Shift. Batch Normalisation besteht aus zwei Algorithmen. Algorithmus 1 verändert den eigentlichen Input von Layer n zu einen normalisierten Input y und Algorithmus 2 verändert das eigentliche Training eines Batch normalisierten Netzwerkes (Ioffe & Szegedy, 2015).

Algorithm 1: Batch Normalisierung angewand auf x über Input bei Mini-Batch

1 Input: Werte von x über einen Mini-Batch $B = \{x_1, \dots, x_n\}$

$$2 \quad \mu_B \leftarrow \frac{1}{m} \sum_{i=1}^m x_i$$

$$3 \quad \sigma_B \leftarrow \frac{1}{m} \sum_{i=1}^m (x_i - \mu_B)^2$$

$$4 \quad \hat{x}_{iB} \leftarrow \frac{x_i - \mu_B}{\sqrt{\sigma_B + \epsilon}}$$

$$5 \quad y_i \leftarrow \gamma \hat{x}_i + \beta \equiv BN_{\gamma; \beta}(x_i)$$

6 Output: $\{y_i = BN_{\gamma; \beta}(x_i)\}$

In Schritt 2 des Algorithmus 1 wird der Erwartungswert für alle Input von Mini-Batch B berechnet und In Schritt 3 die Varianze. In Schritt 3 wird nun der der normalisierte x_i berechnet welche dann mit dem β und γ multipliziert werden. Diese Werte sind neue Gewichte im Neuronalen Netzwerk welche während des Trainingsprozesses angepasst werden. ϵ in der Gleichung in Zeile 4 ist nur dafür da damit nicht durch 0 geteilt werden kann. In Zeile 8 - 11 werden die Inferenz Schritte beschrieben bei den der Minibatch des Trainings ersetzt wird.

Algorithm 2: Training mit Batch-Normalisierungs Netzwerk

- 1 Input: Netzwerk N mit trainierbaren Parameter $\theta; \{x^{(k)}\}_{k=1}$
 - 2 Output: Batchnormalisiertes Netzwerk
 - 3
 - 4
 - 5
 - 6
 - 7
 - 8
 - 9
 - 10
 - 11
 - 12
-

Schritt 1 bis 5 des Algorithmus 2 baut das ANN durch die Transformationen aus Algorithmus 1 um. In Schritt 6 und 7 geht es darum die Parameter γ und β zu trainieren. Dieses passiert mit den üblichen Backpropagation Algorithmus wären des allgemeinen Training des Netzwerkes.




Abb. 6. Neuronales Netzwerk mit Batch Normalication Layer

2.2 Datenformat Punktwolken

Punktwolken sind eine Menge von N Punkten welche im Vektorraum dargestellt werden können. Jeder Punkt $n \in N$ wird durch seine (x,y,z) Koordinaten im Euklidischen Raum dargestellt. Punkte können zusätzliche Features gegeben werden wie Farbe oder Material. Es gibt unterschiedliche Dateiformate welche für die Abspeicherung von Punktwolken herangezogen werden können Beispiele dafür sind PLY, STL oder OBJ. Das Polygon File Format (PLY) speichert die einzelnen Koordinaten in einer Liste diese wird Vertex List genannt. In Abb. 7 kann eine Beispieldatei entnommen werden in der dieser Aufbau dargestellt ist.

```
1 ply
2 format binary_little_endian 1.0
3 element vertex 2800
4 property float x
5 property float y
6 property float z
7 end_header
8 0 0 0
9 0 0 1
10 0 1 1
11 0 1 0
12 1 0 0
13 1 0 1
14 1 1 1
15 1 1 0
16 1 0 0
17 1 0 1
18 1 1 1
19 1 1 0
20 1 0 0
```

Abb. 7. Polygon File Format

Diese kann als Menge betrachtet werden die jeweiligen Punkte sind geordnet in dieser Liste gespeichert jedoch spielt es keine Rolle für den Punktwolken-compiler bei der Visualisierung der Liste an welcher Listenposition ein jeweiliger Punkt geführt wird, die Liste wird jedes mal gleich angezeigt egal welche Permutation der einzelnen Punkte in der Liste durchgeführt wird. In Abb. 8 kann eine visualisierte Punktwolke eines Tabakblattes entnommen werden.




Abb. 8. Punktwolke eines Tabakblattes

2.2.1 Datenaufnahme von Tabakpflanzen

Die Daten stammen von TERRA-REF Feld Scanner von der University von Arizona Maricopa Agricultural Center and USD Arid Land Research Station in Maricopa. Es ist der größte Feld crop scanner. In Abb. ?? ist dieser abgebildet. In Abb. 9 ist der Scankopf des TERRA-REF dargestellt mit den unterschiedlichen Scanmöglichkeiten für das zu scannende Objekt.




Abb. 9. Scankopf

Der 3D Laser Scanner erzeugt 3D Punktwolken. Dabei werden die Objekte durch den Scanner erfasst und eine 3D Repräsentation welche durch Punkte in einen 3 Dimensionalen Koordinaten System erfasst werden können dargestellt. Dabei wird ein Laser über das zu scannende Objekt gefahren durch reflektion des Laserstrahls auf der Oberfläche des Objektes können x,y,z Koordinaten des jeweiligen Punktes auf den Objekt bestimmt werden. Durch die Sammlung einzelner Scanpunkte entsteht eine 3D-Repräsentation eines Gegenstandes.

2.2.2 Das Problem mit 3D-Data bei Machine Learning Ansätzen

Vergleicht man 3D-Data auf ihre Dimensionalität mit anderen Datenformaten wie Bild,- , Audio ,- Textdateien steigt der Informationsgehalt und dadurch die Komplexität für das Anwenden von Maschine Learning Algorithmen enorm. Besonders bei Nicht-Euklidischen 3D-Daten wie Punktwolken deren keine Struktur zu Grunde liegt ist dieses gegeben (Ahmed et al., 2018).

Wie im Kapitel "Woher stammen die Daten" gezeigt, sind Punktwolken als Menge gespeichert in denen keine Relation untereinander besteht, das heißt es ist für den Punktwolkencompiler nicht von Relevanz auf welchen Platz die einzelnen Punkte abgespeichert werden, die Punktwolke wird egal in welcher Permutation der einzelnen Punkte abgespeichert, immer gleich angezeigt. Vergleicht man nun ein Bild mit 512 Pixeln und 3 RGB-Farbkänen ist einer Dimension von 391680 erreicht. Vergleichen wir nun das mit einer Punktwolke in einen 125 cm³ großen Bereich. Da die einzelnen Koordinaten eines Punktes als Rationale Zahlen dargestellt wird und rationalen Zahlen abzählbar Unendlich ist unser Suchraum Unendlich groß. Dies führt zu einem erheblichen mehr Aufwand für Machine Learning Ansätzen wie Deep Learning für Punktwolken.

Ein weitere Schwierigkeit die für Deep Learning mit Punktwolken ist, dass die aus Kapitel Convolutional Neural Network beschriebenen Convolutional-Layer einen großen Beitrag bei den Fortschritt von Deep Learning gebracht hat. Da sie helfen die Strukturen von strukturierten Daten zu lernen und den latenten Raum zu entdecken. Da jedoch Pointclouds unstrukturiert sind hilft es nicht diese Tools bei Punktwolken einzusetzen (Achlioptas, Diamanti, Mitliagkas, & Guibas, 2018).

2.3 Convolution Neural Networks

Convolution Neural Networks(CNN) sind eine besondere Art von künstlichen neuronalen Netzwerken, sie sind dafür konzipiert auf Datensätzen zu arbeiten welche in eine Matrix Form gebracht worden sind. Der Input eines CNN können

beispielsweise Bilder sein welche durch die Matrix $A = \begin{bmatrix} a_1 & a_1 & \dots & a_n \\ b_1 & b_2 & \dots & b_n \\ \vdots & n_n & \ddots & \vdots \\ x_1 & x_2 & x_3 & x_n \end{bmatrix}$

dargestellt werden. Jedes Element x_{ij} stellt einen Pixel eines Bildes da, wobei $x_n \in [0,255]$. Die Matrix $A^{w \cdot b \cdot c}$ stellt $w \cdot b \cdot c = N$ dimensionale Matrix da. Wobei w die Länge und b Breite des Bildes entspricht. c sind die Farbspektren eines Bildes und sind in einen RGB-Farbraum 3 beziehungsweise in einen schwarz-weiß Bild 1. Nachdem der Input eines CNN definiert ist kommt nun der Aufbau. CNN setzen sich aus mehrere Schichten von Convolution Layern zusammen. Ein Netzwerk kann mehrere N-Layer haben. Wobei jeder Layer aus mehreren Convolution oder auch Kernels genannt, zusammengesetzt ist. Ein Aufbau kann aus Abbildung 24 entnommen werden (Goodfellow et al., 2016).

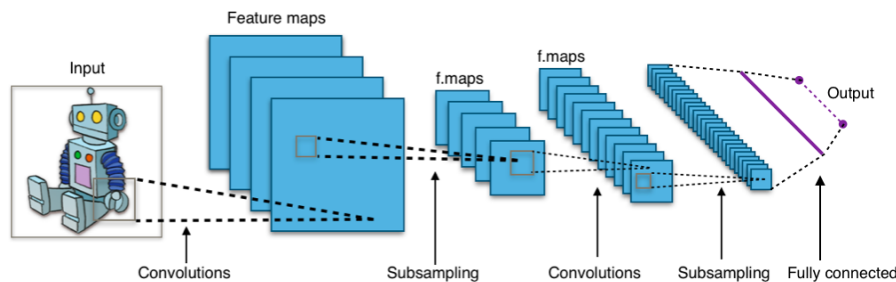


Abb. 10. Convolutional Neural Network

Die Kernels, also die einzelnen Filter, von den jeder der N-Layer k besitzt sind $K^{n \times n}$ Matrizen jedes k_{ij} in einem Filter entspricht einen aus der üblichen Neuronalen Netzwerk Architektur bekannten Gewichte. Diese Gewichte werden dann durch den Backpropagation-Algorithmus in der Trainingsphase des Netzwerkes angepasst um den Verlust der Loss-Funktion durch bestimmten des Gradienten zu minimieren. Das durch die Abbildung 24 dargestellte Subsampling ist der Output aus den Convolutional Layern (Goodfellow et al., 2016).

Da Input und Kernel unterschiedliche Größen haben und man den gesamten Input mit den Kernel abdecken möchte, bewegt sich der Filter um s Position auf den Input und führt erneut einen Berechnungsschritt durch. Dieser Vorgang wird Stride genannt. An jeder Position wird das Produkt von jedem x_{ij} des Input und k_{ij} des Kernel durchgeführt. Anschließend werden alle Produkte aufsummiert. In Abbildung 11 ist dieser Vorgang verdeutlicht. Zusätzlich gibt es die Möglichkeit für das sogenannte Zero Padding P . Dabei werden mehrere 0 um die Input Feature Map, am Anfang und Ende der Axen anfügt. Dies ist notwendig wenn Kernel und Input Größe nicht kompatibel zueinander sind. Die Anzahl der möglichen Positionen ergeben sich aus Kernel Größe und den Input des jeweiligen Kernel sowie des Strides. Die Output Größe W kann berechnet werden durch $W = (W-F+2P)/s+1$. Wobei F für die Größe des Kernel steht (Dumoulin & Visin, 2016).

Um besser zu verstehen welche Auswirkungen die Anzahl der Kernels in Layer n auf die Größe des Outputs von n und die Anzahl der Kernels in Layer $n+1$ für den nächsten Layer haben, wird ein Beispiel aufgezeigt. Der erste Layer hat 20 Kernels mit der Größe 7×7 und Stride 1. Der Input A für einen Kernel K ist ein 28×28 Matrix. Der Output aus diesen Filter sind 20 22×22 Feature Maps. Würde der Input ein $28 \times 28 \times 3$ Bild mit 3 RGB Channels sein, der Output 60 22×22 Feature Maps. Allgemein kann Convolution Layer als Subsampling gesehen werden und Stride gibt an wieviele Dimensionen bei diesen Prozess pro Convolution Layer entfernt werden soll. Der letzte Layer ist ein fully-connected Layer welcher den typischen Anforderungen von ANN entspricht (Dumoulin & Visin, 2016).

Transposed Convolution, auch genannt Fractionally Strided Convolution oder Deconvolution ist eine Umkehrfunktion von der üblichen Convolution. Es ver-




Abb. 11. Convolution Beispiel

wendet die gleichen Variablen wie Convolution. Dabei wird ein Kernel K mit der Größe $N \times N$ definiert der Input I mit der Größe $N \times N$ und Stride $s = 1$. Deconvolution kann wie Convolution angesehen werden mit Zero Padding auf dem Input. Das in Abbildung 12 gezeigte Beispiel zeigt einen deconvolution Vorgang mit eine 3×3 Kernel über einen 4×4 Input. Dies ist gleich mit einen Convolution Schritt mit einen 3×3 kernel auf einen 2×2 Input und einer 2×2 Zero Padding Grenze. Convolution ist Supsampling und mit Deconvolution wird Upsampling betrieben. Durch diesen Schritt kommt es zu einer Dimensionserhöhung des Inputs. Die Gewichte der Kernels bestimmen wie der Input transformiert wird. Durch mehrere Schichten von Deconvolution Layer kann von einer Input Größe $N \times N$ auf eine Output Größe $K \times K$, wobei $K > N$ mit Abhängigkeit von Kernel und Stride abgebildet werden (Dumoulin & Visin, 2016).




Abb. 12. Deconvolution Beispiel

2.4 Autoencoder

Autoencoder gehören zu den generativen Modellen im Bereich des Machine Learnings. Generative Modelle haben das Ziel eine Wahrscheinlichkeitsverteilungen zu erlernen. Anschließend kann diese als ein Modell genutzt werden und Samples aus dieser zu erzeugen. Die Modelle können dabei beispielsweise auf ANN oder Markov Chains trainiert werden (Goodfellow et al., 2016). Im folgenden liegt der Fokus auf ANNs. Allgemein gehalten können jegliche Typen von Daten wie Text, Bild oder Audiodateien für generative Modelle herangezogen werden. Es gibt unterschiedliche Typen von generativen Modellen, welche sich vom Aufbau des Neuronalen Netzwerk und der Zielfunktion unterscheiden. Beispiele dafür sind Boltzmann Maschine, Autoencoder oder Deep Belief Networks (Goodfellow et al., 2016).

Autoencoder sind ein andere Art von Model aus den Bereich der generativen Modelle. Ihre Aufgabe besteht darin einen Input zu komprimieren und aus der komprimierten Information den Input wieder herzustellen. Die Technik auf welche Autoencoder zurückgreifen nennt sich Dimensionreduktion. Dabei werden die Dimension der Daten so reduziert und Informationen bei zu behalten welche als relevant gelten. Diese Technik finden auch in anderen Machine Learning Anwendung wie in beispielsweise der Principale component analysis (PCA) Anwendung (Hinton & Salakhutdinov, 2006). Ein Autoencoder besteht aus 2 Bestandteilen. Erstens ein Encoder e parametrisiert mit ϕ welcher einen Input $x \in \mathbb{R}^i$ wo x ein Vektor der Länge i ist und damit die Input Dimension bestimmt. Dieser wird durch den Encoder auf einen Vektor z^k abgebildet wobei $k < i$ ist. Zweitens der Decoder d parametrisiert durch θ bekommt als Input z^k und bildet z auf \mathbb{R}^i ab wobei $i = k$. Und somit die gleiche Dimension wie der Input. Aufgabe ist es nun das der Encoder den Input x so gut komprimiert das der Decoder es schafft das $x \approx z$. Eine grafische Darstellung kann aus Abb. 13 entnommen werden (Goodfellow et al., 2016).

Die Parameter ϕ und θ werden durch den in Kapitel 2.1.2 vorgestellten Algorithmus trainiert und erlernt. Und können beispielsweise durch Fully-Connected-Layer, Convolutional-Layer oder Deconvolutional-Layer modelliert werden. Eine Metrik um zu messen wie das Model seine Aufgabe erfüllt könnte Beispielsweise die Cross-Entropy-Funktionen sein welche schon in Kapitel 2.1.1 vorgestellt worden ist. Weitere spezifische Zielfunktionen für Autoencoder welche mit 3D Punktwolken arbeiten und für die folgende Arbeit von belangen sind, werden nun vorgestellt.

Bei Punktwolken als Datentyp erzielt die Cross-Entropy-Funktion keine gute Ergebnisse da diese invariant zu ihrer Permutation sind. Dies Da in der Arbeit der Input 3d Pointcloud sind und diese Sets invariant zu ihren Permutationen sind Das heißt ändere ich die Anordnung meiner einzelnen Punkte in mein Set bleibt das Ergebnis unverändert. Kann auf übliche Zielfunktionen welche für strukturierte Daten wie Bilder verwendet werden nicht zurück gegriffen. Das Problem dabei besteht das zwischen zwei unterschiedliche Sets von Punkten heraus




Abb. 13. Autoencoder

zu finden wie hoch die Diskrepanz zwischen den beiden Sets ist (Ravanbakhsh, Schneider, & Poczos, 2016).

Eine Möglichkeit speziell für Autoencoder welche mit Punktwolken arbeiten, ist die Earth Mover Distance (EMD). Bei dieser sind X_1 und X_2 zwei Punktwolken mit jeweils x_n definierten Punkten (Fan, Su, & Guibas, 2017). Definiert ist sie durch die Funktion:

$$d^{\text{EMD}} = \min_{\theta: X_1 \rightarrow X_2} \sum_{x \in X_1} \|x - \theta(x)\|_2 \text{ wobei } \theta: X_1 \rightarrow X_2 \text{ bijektiv ist}$$

Grafisch kann man sich die Berechnung wie in Abb. 14 darstellen. Ein Punkt von $x_n \in X_1$ wird den nächsten Punkt $y_n \in X_2$ zugewiesen. Wobei die Distanz durch die Euklidische Distanz der jeweiligen Punkte ermittelt wird.

Eine weitere Möglichkeit ist die Chamfer Distance (CD). Wie auch zuvor sind X_1 und X_2 zwei Punktwolken mit jeweils x_n definierten Punkten (Fan et al., 2017). Definiert ist sie durch die Funktion:

$$d^{\text{CD}}(X_1, X_2) = \sum_{x \in X_1} \min_{y \in X_2} \|x - y\| + \sum_{y \in X_2} \min_{x \in X_1} \|x - y\|$$

Der Unterschied ergibt sich zwischen den beiden das bei der EMD von der Ausgangswolke die Punkte zu der anderen jeweils optimiert werden. Wohingegen bei der CD die Distanzen von und zu der Ausgangspunktwolke berechnet werden. Dies geht aus den Abb. 15 hinaus in welche die Distanzberechnung der einzelnen Punkte dargestellt wird (Fan et al., 2017).




Abb. 14. Earth Mover Distance




Abb. 15. Chamfer Distance

2.5 Generative Adversarial Network

In den letzten Jahren konnte sich das GAN als best practice Ansatz bei den generativen Modellen herausarbeiten was Performancegründe bei der Trainierbarkeit und Qualität der generierbaren Daten zu Grunde liegt (Goodfellow et al., 2016). Die Modelle arbeiten nach der Maximum Likelihood Schätzverfahren (ML-Schätzer) in dem die Parameter θ dahingegen angepasst werden, dass die unsere beobachtet Daten am ehesten passen. Man kann ML-Schätzer als Kulback-Leibler (KL) Divergenz darstellen und das generative Modelle das Ziel haben die KL Divergenz zwischen den Trainingsdaten P_r und den generierten Daten P_g zu minimieren. Diese ist definiert durch:

$$KL(P_r || P_g) = \int_x P_r \log \frac{P_r}{P_g} dx$$

Ein GAN besteht aus zwei KNN, dem Discriminator D und dem Generator G. Das Ziel des G ist es, Daten x zu erzeugen, welche nicht von Trainingsdaten y unterschieden werden können. Dabei wird eine vorangegangene Input Noise Variable $p_z(z)$ verwendet, welche eine Abbildung zum Datenraum $G(z; \Phi_g)$ herstellt. Dabei sind Φ_g die Gewichte des neuronalen Netzwerkes von G. Der Discriminator hat die Aufgabe zu unterscheiden, ob der jeweilige Datensatz von G erzeugt wurde und somit ein fake Datensatz ist, oder von Trainingsdaten y stammt (Goodfellow et al., 2014). Die Zusammensetzung zwischen den beiden Netzwerken kann aus Abbildung 16 entnommen werden.




Abb. 16. Generativ Adversarial Network

Der Discriminator ist definiert durch $D(x; \Phi_d)$. Wobei Φ_d die Gewichte des Discriminators sind und $D(x)$ die Wahrscheinlichkeit ist, dass x von den Trainingsdaten stammt und nicht von p_g . Die Wahrscheinlichkeitsverteilung für unsere Trainingsdaten ist p_r . Im Training werden dann Φ_d so angepasst, dass die Wahrscheinlichkeit Trainingsbeispiele richtig zu klassifizieren maximiert wird. Und Φ_g wird dahingegen trainiert die Wahrscheinlichkeit zu minimieren, so dass D

erkennt dass Trainingsdatensatz x von G erzeugt wurde. Mathematisch ausgedrückt durch $\log(1 - D(G(z)))$. Die gesamte Loss-Funktion des vanilla GAN ist definiert als

$$\min_G \max_D V(D, G) = E_{x \sim p_{\text{data}}(x)} [\log D(x)] + E_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$

diese beschreibt ein Minmax Spiel zwischen G und D . Welches das globale Optimum erreicht hat wenn $p_g = p_r$. Das heißt, wenn die Datenverteilung, welche von G erzeugt wird, gleich der unserer Trainingsdaten ist (Goodfellow et al., 2014). Das Training erfolgt durch den folgenden Algorithmus:

Algorithm 3: Minibatch stochastic gradient descent Training für Generative Adversarial Networks. Die Anzahl der Schritte welche auf den Discriminator angewendet wird ist k

```

1 for Anzahl von Training Iterationen do
2   for k Schritte do
3     • Sample minibatch von  $m$  noise Samples  $z^{(1)}, \dots, z^{(m)}$  von noise
       $p_g(z)$ 
4     • Sample minibatch von  $m$  Beispielen  $x^{(1)}, \dots, x^{(m)}$  von Daten
      Generationsverteilung  $p_{\text{data}}(x)$ 
5     • Update den Discriminator zum aufsteigenden stochastischen
      Gradienten:
6      $\nabla_{\Phi_d} \frac{1}{m} \sum_{i=1}^m [\log D(x^{(i)}) + \log(1 - D(G(z^{(i)})))]$ 
7   end
8   • Sample minibatch von  $m$  noise Samples  $z^{(1)}, \dots, z^{(m)}$  von noise  $p_g(z)$ 
9   • Update den Generator mit den absteigenden stochastischen
      Gradienten:
10   $\nabla_{\Phi_g} \frac{1}{m} \sum_{i=1}^m \log(1 - D(G(z^{(i)})))$ 
11 end
```

Beim Training wird ein stochastischer Minibatch von mehreren Trainingsdaten gleichzeitig erstellt. Dies soll dabei helfen, dass der Generator sich nicht auf bestimmte Gewichte fest fährt und auf Trainingssätze kollabiert. So weisen die erzeugten Daten mehr Variationen auf (Salimans et al., 2016). D wird zunächst in einer inneren Schleife auf n Trainingsätzen trainiert, womit man Overfitting von D vermeiden will, was zur Folge hätte, dass D nur den Trainingsdatensatz kopieren würde. Deshalb wird k mal D optimiert und ein mal G in der äußeren Schleife.

Ein möglicher Aufbau von GAN wird in Abbildung 18 dargestellt. Dies ist das sogenannte Deep Convolution GAN (DC GAN), welches dafür konzipiert wurde auf Bilddaten zu arbeiten. Dabei besteht der Generator aus mehreren Schichten von Deconvolution Layern. Welche den Input Noise Variable $p_z(z)$ auf y abbildet. D besteht aus mehreren Schichten von Convolution Layern und bekommt als Input die Trainingsdaten, oder die von G erzeugten Y , und entscheidet über die Klassifikation (Radford, Metz, & Chintala, 2015).




Abb. 17. Deep Convolutional GAN

Wie unter Generativen Modellen gezeigt wurde kann das asymmetrische Verhalten der KV Divergenz zu schlechten Trainingsergebnissen führen. Goodfellow (Goodfellow et al., 2014) zeigte, dass sich die MinMax Loss-Funktion des GAN auch als Jensen-Shannon Divergenz(JS Divergenz) darstellen lässt. Diese ist definiert als

$$D_{JS}(P_r || P_g) = \frac{1}{2} D_{KL}(P_r || \frac{P_g + P_r}{2}) + D_{KL}(P_g || \frac{P_g + P_r}{2})$$

wobei P_r die Wahrscheinlichkeitsverteilung der Trainingsdaten ist und P_g die des Generators. Huzár (Huszár, 2015) zeigte, dass durch das symmetrische Verhalten der JS Divergenz ein potentiell besseres Trainingsergebnis entstehen kann, im Vergleich zu der KL Divergenz. Damit zeigte er weshalb GANs im Vorteil gegenüber anderen generativen Modellen sind. Abbildung 18 veranschaulicht dieses Konzept. Der linke Graph zeigt 2 Normal Verteilungen. In der Mitte wird die KV Divergenz der beiden Normal Verteilungen dargestellt. Rechts ist die JS Divergenz der Beiden dargestellt. Man sieht sehr gut das asymmetrische Verhalten der KV und das symmetrische der JS. Dadurch lassen sich aussagekräftigere Gradienten bestimmen, welche zum Optimieren von D und G benötigt werden(Huszár, 2015).




Abb. 18. KL Divergenz und JS Divergenz

2.5.1 Probleme mit Generative Adversarial Networks

Wie auch anderen generativen Modelle haben auch GANs noch Schwächen bezüglich der Trainingsabläufe und der Qualität der generierten Daten. Im Folgenden wird auf einige Probleme eingegangen welche im darauffolgenden Kapitel Lösungsansätze aufgezeigt werden.

Equilibrium

D und G betreiben ein MinMax Spiel. Beide versuchen das Nash Equilibrium zu finden. Dies ist der bestmögliche Endpunkt in einen nicht kooperativen Spiel. Wie in dem Fall von GAN wäre das wenn $p_g = p_r$. Es wurde gezeigt, dass das Erreichen dieses Punktes sehr schwierig ist, da durch die Updates der Gewichte mit den Gradienten der Loss-Funktion starke Schwingungen der Funktion entstehen können. Dies kann zur Instabilität für das laufende Training führen (Salimans et al., 2016).

Vanishing gradient

Dies beschreibt das Problem, wenn D perfekt trainiert ist mit $D(x) = 1, \forall x \in p_r$ und $D(x)=0 \forall x \in p_g$. Die Loss-Funktion würde in diesem Fall auf 0 fallen und es gäbe keinen Gradienten, für den die Gewichte von G angepasst werden können. Dies verlangsamt den Trainingsprozess bis hin zu einem kompletten Stopp des Trainings. Würde D zu schlechten trainiert mit $D(x) = 0, \forall x \in p_r$ und $D(x)=1 \forall x \in p_g$. Bekommt G kein Feedback über seine Leistung bei der Datengeneration hat er keine Möglichkeit p_r zu erlernen (Salimans et al., 2016).

Mode Collapse

Während des Trainings von GAN kann es dazu kommen, dass der Generator möglicherweise auf eine Einstellung seiner Gewichte fixiert wird und es zu einem sogenannten Mode Collapse führt. Was zur Folge hat, dass der Generator sehr ähnliche Samples produziert (Arjovsky, Chintala, & Bottou, 2017).

Keine aussagekräftigen Evaluations Metriken

Die Loss Funktion der GANs liefert keine aussagekräftigen Evaluationsmöglichkeit über den Fortschritt des Trainings. Bei discriminativen Modellen im üblichen Maschine Learning besteht die Möglichkeit Validierungsdatensätze zu verwenden und an diesen die Genauigkeit des Modells zu testen. Diese Möglichkeit besteht bei GANs nicht (Huang et al., 2018).

2.5.2 Lösungsansätze für Generative Adversarial Networks Probleme

Nun werden einige Techniken aufgezeigt, welche die unter Abschnitt Probleme mit GAN genannten Schwierigkeiten angehen und zu einem effizienteren Training führen, damit eine schnellere Konvergenz während des Trainings erreicht wird.

Feature matching

Dies soll die Instabilität von GANS verbessern und gegen das Problem des Vanishing Gradient angehen. G bekommt eine neue Loss-Funktion und ersetzt die des üblichen Vanilla GAN. Diese soll G davon abhalten, sich an D über zu trainieren und sich zu sehr darauf zu fokussieren, D zu täuschen und gleichzeitig auch versuchen die Datenverteilung der Trainingsdaten abzudecken (Salimans et al., 2016).

Minibatch discrimination

Um das Problem des Mode Collapse zu umgehen, so dass es nicht zu einem Festfahren der Gewichten von G kommt, wird beim Trainieren die Nähe von den Trainingsdatenpunkten gemessen. Anschließend wird die Summe über der Differenz aller Trainingspunkte genommen und dem Discriminator als zusätzlicher Input beim Training hinzugegeben (Salimans et al., 2016).

Historical Averaging

Beim Training werden die Gewichte von G und D aufgezeichnet und je Trainingsschritt i verglichen. Anschließend wird an die Lossfunktion je Trainingsschritt die Veränderung zu i-1 an die Loss-Funktion addiert. Damit wird eine zu starke Veränderung bei den jeweiligen Trainingsschritten bestraft und soll gegen ein Model Collapse helfen (Salimans et al., 2016).

One-sided Label Smoothing

Die üblichen Label für den Trainingsdurchlauf von 1 und 0 werden durch die Werte 0.9 und 0.1 ersetzt. Dies führt zu besseren Trainingsergebnissen. Es gibt derzeit nur empirische Belege für den Erfolg, jedoch nicht weshalb diese Technik besser funktioniert (Salimans et al., 2016).

Adding Noises

Noise an den Input von D zu hängen kann gegen das Problem des Vanishing gradienten helfen und das Training verbessern (Salimans et al., 2016).

Wasserstein-GAN

Die Wasserstein Metric oder auch Earth Mover Distance (EMD) genannt misst die Minimum Kosten welche entstehen wenn man Daten von der Datenverteilung p_r zur Datenverteilung p_g überträgt. Es wird oft auch von Masse oder Fläche gesprochen, welche von p_r zu p_g getragen wird. Definiert ist sie durch:

$$W(p_r, p_g) = \inf_{\gamma \in \Pi(p_r, p_g)} \mathbb{E}_{(x, y) \sim \gamma} [\|x - y\|]$$

p_r steht für die reale Datenverteilung zu welche uns Daten im Form von Trainingsdaten zur Verfügung stehen und p_g steht für die generierte Datenverteilung welche von einem Model erzeugt wird. Dabei wird nun das Infimum von allen möglichen Transportplänen γ welche in Π enthalten sind ausgewählt, welche der kostenkünstige Plan ist die Daten von p_g zu p_r zu

übertragen. Vorteile sind unter anderem, dass der Gradient gleichmäßiger ist und das WGAN lernt besser auch wenn der Generator schlechtere Daten erzeugt im Vergleich zum üblichen GAN (Arjovsky et al., 2017). Durch die Kantorovich-Rubinstein Methode kann die Wasserstein-Distanz umgeformt werden in zu:

$$W(p_r, p_\theta) = \sup_{\|f\|_L \leq 1} E_{x \sim p_r}[f(x)] - E_{x \sim p_\theta}[f(x)]$$

Durch diese Umformung ist es nun Möglich das GAN die EMD nutzt um die von G generierten Daten mit den realen Daten zu vergleichen. Dabei übernimmt der Discriminator nun die Aufgabe eines Critic welcher nun nicht mehr 0 oder 1 für Fake oder Real ausgibt sondern einen Score welcher angibt wieviel Masse von der p_θ umverteilt werden muss damit der Generator bessere Ergebnisse liefert. Das Wasserstein GAN liefert bis dahin die erfolgreichste Verbesserung zum üblichen Vanilla-GAN von Goodfellow und erlaubt es gegen die in Kapitel 2.5.1 aufgezeigten Probleme Vanishing gradient und Model Collapse anzugehen (Arjovsky et al., 2017).

2.6 Conditional-GAN

Conditional-GAN (C-GAN) ist eine Modifikation des ursprünglichen GAN von Goodfellow, welches erlaubt bedingte Wahrscheinlichkeiten in Datensätze zu erlernen. Das heißt zusätzliche Informationen in den Lernprozess einzuspeisen um den Output zu modifizieren. Im ursprünglichen GAN gibt es keine Möglichkeit auf den Output des Generators Einfluss zu nehmen. Dabei wird das Modell so verändert das eine zusätzliche Information y als Input in den Discriminator und Generator zugefügt wird. Dabei kann y jegliche Information sein wie Label, Bilddaten oder 3D-Daten. Dem entsprechend muss die Zielfunktion dahin gehen angepasst werden bedingte Wahrscheinlichkeiten zu lernen

$$\min_G \max_D V(D, G) = E_{x \sim p_{\text{data}}(x)}[\log D(x|y)] + E_{z \sim p_z(z)}[\log(1 - D(G(z|y)))]$$

Im Abb. 34 kann der Informationsfluss und die Konnektivität der einzelnen Module entnommen werden. Die Module Generator und Discriminator bleiben gleich und können von ihren Aufbau für die jeweiligen Datentyp verändert werden und Beispielsweise durch Convolutional-Layer, Deconvolutional-Layer oder Fully-Connected-Layer bestehen. (Radford et al., 2015).

2.7 3D-GAN

Das besondere an den 3D Raum im Vergleich zu Normalen 2D Bildern ist die Steigerung der Dimension und zu gleich der hohe Informationsgehalt welcher in 3D Objekten steckt. Das Ziel von 3D-GAN ist es die Datenverteilung der zugrunde liegenden 3D-Modellen zu erlernen. Dabei wird der latente Objektraum erfasst und soll dadurch die Wahrscheinlichkeiten für einzelne Objektklassen enthalten.

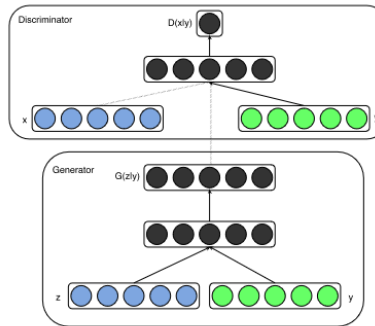


Abb. 19. Conditional Adversarial Network

Es wurden schon mehrere Versuche von generativen Modellen auf 3D Daten durchgeführt wie von Wu, Jiajun und Zhang (Wu, Zhang, Xue, Freeman, & Tenenbaum, 2016) welche in ihren Modell mit mit 3D-Voxel Daten arbeiten und damit ein GAN trainiert haben oder Achlioptas, Panos und Diamanti (Achlioptas et al., 2018) welche ein GAN auf Punktwolken trainiert. Da in folgender Arbeit die 3D-Daten durch Punktwolken dargestellt werden wird die Arbeit von Achlioptas, Panos und Diamanti näher beleuchtet.

Die Architektur des typischen 3D-GAN in dieser Arbeit als RAW-GAN betitelt ist dem Vanilla GAN von Goodfellow ähnlich. Der Input Layer ist ein Fully-Connected Layer welcher der Anzahl der Punkte je Punktwolke $\cdot 3$ entspricht. Dieser bekommt als Input einen Noise-Vektor welcher aus einer Gausischen Verteilung entnommen wird und durch mehrere Layern gereicht bis hin zum Output Layer welche die Anzahl der gewünschten Punkte besteht. Also Zielfunktion kann mit der KL-Zielfunktion gearbeitet werden oder mit der Wasserstein Metrik welche im Versuchsaufbau von Achlioptas, Panos und Diamanti besser Ergebnisse geliefert hat. Der Aufbau unterscheidet sich nicht von Vanilla-GAN (Achlioptas et al., 2018).

Eine weitere Möglichkeit ist das Latent-GAN, dieses benutzt eine andere Aufbau gegenüber dem RAW-GAN, welches dabei helfen soll den latenten Raum der Objekte zu erlernen. Zunächst wird ein Autoencoder mit den vorhandenen Trainingsdaten (siehe Autoencoder) trainiert. Der Aufbau ist der selbe einen üblichen Autoencoder beschrieben in Kapitel 2.4. Ziel dabei ist den latenten Raum der Trainingsdaten zu erlernen und eine Kompression der Daten um den Suchraum zu welcher beim RAW-GAN durch die Inputdimension gegeben ist zu verringern und dadurch das Training des GANs zu erleichtern (Achlioptas et al., 2018).

Bevor das Training des Latent-GAN beginnen kann wird nun meine Trainingsdaten durch den vorher trainierten Encoder des 3D-Autoencoder auf die festgelegte Output-Dimension komprimiert. Anschließend werden diese komprimierten




Abb. 20. Latent-GAN

Daten verwendet um das GAN zu trainieren. Dabei erlernt das GAN komprimierte Code zu produzieren welche anschließend durch den Decoder des 3D-Autoencoders wieder auf die ursprüngliche Größe gebracht werden kann. Durch dieses Verfahren war es ihnen möglich Daten in einer guten Qualität zu produzieren und eine Datenverteilung des zugrundeliegenden Modells zu erlernen. Der gesamte Ablauf kann in 20 entnommen werden (Achlioptas et al., 2018).

2.8 Rekonstruktion von Daten

Derzeit setzt Deep Learning neue Maßstäbe bei der Rekonstruktion von Daten wie Bildern oder Texten. Bei der Rekonstruktion geht es darum das Daten welche von ihren Urzustand verändert wurden, sei es durch Artefakte oder manuelle Bearbeitung wieder dahin zurück zu führen. In Abb. 21 ist eine Rekonstruktion eines Bildes dargestellt welches eine Wiederherstellung eines Hundes zeigt. Deep Learning hat in diesen Bereich besonders bei Bildern große Erfolge erlangt, dadurch dass diese als Matrizen dargestellt werden können liefern sie eine Datenstruktur auf welche KNN arbeiten können. Auch durch Bearbeitung mit Convolutionen-Layer auf Bilddaten zählt als Erfolg für die Weiterverarbeitung (Dong, Loy, He, & Tang, 2016a). Durch die genannten Methoden werden bessere Strukturen für das jeweilige Ziel, in diesem Fall der Rekonstruktion gelernt und ermöglicht es wie in verschiedenen Papern wie (Dong, Loy, He, & Tang, 2016b) welche auf super-hochauflösenden Bildern Artefakte entfernt und das Bild wieder zum Urzustand zurück führt.

Ebenso wie die Arbeit von Liu, Gulin und Reda (Liu et al., 2018) welche ähnliche Ergebnisse liefern konnte. Rekonstruktion auf 3D-Daten wurde von Yi, Li und Shao (Yi et al., 2017) durchgeführt diese Arbeit beinhaltet jedoch die Rekonstruktion von 2D Bildern auf 3D Modellen. Bei wurde mit Hilfe von Autoencodern gearbeitet welche auf für die folgenden Arbeit von Bedeutung sind. (Yi et al., 2017).



Abb. 21. Bild Rekonstruktion eines Hundes welches durch ein Artefakt zerstört wurde

3 Methoden

In diesen Kapitel werden die Methoden für die Versuchsaufbauten aufgezeigt welche die Ziele 1 und 2 überprüfen sollen. Dabei geht es darum ob mit hilfe von GAN der latente Objektraum eines Tabakblattes gelernt werden kann und anschließend durch den Generator des GAN Tabakblätter erzeugt werden können. Dieses Versuchsaufbau wird in Kapitel 3.3 behandelt. Die dazugehörigen Trainingsdaten werden in Kapitel 3.1 vorgestellt. Beim Ziel 2 soll überprüft werden ob mit Hilfe von GAN es möglich ist Artefakte von Tabakblätter zu entfernen und den Urzustand wieder her zustellen. Dieses Verfahren wurde in Kapitel 2.8 beschrieben. Die Trainingsdaten für diesen Versuchsaufbau können aus Kapitel 3.2 entnommen werden. Alle Versuche wurden auf einen Computer mit Ubuntu 14.05 Betriebssystem mit einen IntelR CoreTM i7-7700k mit 4.50GHz einer GeForce GTX 1080 mit 8G Grafikspeicher. Training und Testen wurden mit CUDA 9.0 und cudNN 7.1.1. . Also Programmiersprache wurde Python 2.7 bzw. 3.5 für Datengenerierung. Also ANN Library wurde Tensorflow 1.5 genutzt.

3.1 Datensatz 1. Versuchsaufbau

Der erste Datensatz "Stühle" besteht aus 4014 Punktwolken mit je 2056 Punkten. Der Datensatz wurde aus von den Shapenet Datensatz entnommen. Ein Beispieelpunktwolke kann aus Abbildung entnommen werden. Er ist als .ply Datenformat abgespeichert. Dieser Datensatz wurde von (Achlioptas et al., 2018) verwendet welches auch schon in Kapitel 2.7 vorgestellt wurde dieser dient als Validierungsdatsatz um die Qualität der generierten Daten des GAN welches mit Tabakblättern trainiert wurde mit den welches die Stuhl Daten bekommt zu vergleichen.

Die Daten für den zweiten Datensatz "Blätter" stammen vom Fraunhofer Institut deren Gewinnung wurde in Kapitel 2.2 beschrieben. Der Grunddatensatz bestand aus mehreren 3D-Scans von Tabakpflanzen bei den die Blätter der Pflanze zu einen Datensatz zusammengefügt wurden sind. Der "Blätter" Datensatz besteht aus 420 Punktwolken welche dann durch ein Verfahren auf jeweils 2056 Punkten je Punktwolke reduziert wurden ist. Aus Komplexitätsgründen wurden die Farbchannels außen vor gehalten um den Informationsgehalt der Daten zu reduzieren und ein Training zu vereinfachen. Außerdem spielen Farben bei den

derzeitigen Ziel der Arbeit, Rekonstruktion von Tabakblättern keine Rolle und nehmen keinen Einfluss auf die Verwendbarkeit des Ergebnisses. Abgespeichert werden die Daten im .ply Datenformat.



Abb. 22. 3D Punktwolke einer Tabakpflanze




Abb. 23. 3D Punktwolke einer Tabakpflanze

3.2 Datensatz 2. Versuchsaufbau

Für den zweiten Versuchsaufbau wird auf den in Datensatz Versuchsaufbau 1. Blatt Datensatz "Blätter zurückgegriffen. Dabei wird in den Blättern punkte heraus genommen welche das verdecken oder zerstört sein eines Blattes simulieren soll. Dies passiert indem eine Gaußverteilung auf einer 3D-Sphere erzeugt wird. Anschließend wird das Komplement zwischen einem 3D-Blatt und einer 3D-Sphere berechnet das Ergebnis sind zerstörte Blätter mit Kreisrunden Löchern auf der Oberfläche. Der Algrorithmus zum erzeugen der Trainingsdaten kann im Anhang entnommen werden. In Abbildung sind die 3 Abschnitte zu erkennen wie die Trainingsdaten erzeugt werden.

Insgesamt besteht der Trainingsdatensatz aus 450 unzerstörten Blättern sowie 1024 zerstörten paaren.

3.3 Trainingsaufbau 1 - GAN

Der Aufbau besteht aus zwei unterschiedlichen Versuchen. Aufbau 1 ist das RAW-GAN. Dabei wird auf den herkömmlichen Aufbau von GAN zurückgegriffen. Die Allgemeinen Meta-Trainingsvariablen sind Learningrate mit 0,005 und einen Adam Optimizer welcher zu den stochastischen Gradient Descent Verfahren aus Kapitel 2.1.2 und dabei auf das aus Kapitel 2.1.3 zurückgreift, mit einem Beta1 von 0.5 und einem Beta2 von 0,5. Der Discriminator besteht aus 4-Layern welche 1-Dimensionaler Convolutional Layer bestehen. Mit einer Kernel Größe von 1 und Stride von 1. Die Aktivierungsfunktion wird die ReLu-Funktion genutzt. Darauf folgen 3 fully connected Layer mit der Größe 128, 54 und 1 alle mit einer Relu Aktivierungsfunktion.




Abb. 24. 3D Punktwolke einer Tabakpflanze

Der Generator besteht auf 5 fully-connected Layern mit $[64, 128, 512, 1024, 1536]$ Neuronen jeweils mit einer Relu Aktivationsfunktion. Der Aufbau kann in Abbildung entnommen werden. Die Zielfunktion ist die Wasserstein Metric und die Vanilla-GAN Zielfunktion von Goodfellow verwendet (Goodfellow et al., 2014). Der Versuchsaufbau 2 ist das Latent-GAN zunächst wird dabei der Autoencoder mit den Trainingsdaten trainiert. Der Encoder des Autoencoders wird mit einer Learning Rate von 0.0005 trainiert. und einer Batch Größe von 50. Der Encoder besteht dabei besteht dabei aus 4 1-D Convolutional Layern mit $64, 128, 246, 1024$ Filtern Stride von 1 und Size von 1. Die Aktivierungsfunktion ist relu. Der Letzte Layer ist ein Max Layer. Der Decoder besteht aus aus $[256, 256, 614]$

3.4 Trainingsaufbau 2 - CGAN für Punktwolkenrekonstruktion

Da sich im Trainingsaufbau 1 das L-GAN bessere Ergebnisse liefert bei Erlernen von Punktwolken Daten. Wird der Aufbau von L-GAN übernommen und dahin gehen verändert, das Ziel zu erfüllen. Zunächst werden wie bei Trainingsaufbau 1 die Trainingsdaten (siehe Trainingsdaten Aufbau 2) trainiert. Der Aufbau des Autoencoders ist dabei gleich dem von Aufbau 1. Der Encoder des Autoencoders wird mit einer Learning Rate von 0.0005 trainiert. und einer Batch Größe von 50. Der Encoder besteht dabei besteht dabei aus 4 1-D Convolutional Layern mit $64, 128, 246, 1024$ Filtern Stride von 1 und Size von 1. Die Aktivierungsfunktion ist relu. Der Letzte Layer ist ein Max Layer. Der Decoder besteht aus aus $[256, 256, 614]$. Die Zielfunktion ist die Chamfer Distance da sie die besten Ergebnisse bei citierte PGAN besten geliefert hat.

Anschließend werden zerstörten BlatDaten x mit den trainierten Encoder zu den latenten Code y komprimiert, der einen Vektor von 128-D entspricht. Das selbe wird mit den unzerstörten BlattDaten x' gemacht welche mit den Encoder zu dem latenten Code y' komprimiert werden welcher einen Vektor von 128-D entspricht. Wobei es jeweils (x, x') paare Gibt welche den

Der Aufbau des C-GANS entspricht der in im 3.4 beschrieben C-GAN üblichen Aufbau. der Generator bekommt als Input x' und x welches einen 128-D Vektor welcher aus einer Gausischen Verteilung gesamplet wird. Der Generator besteht aus 3 layern [256,128,128] der Diskriminator besteht aus 2 fully Connected Layer mit der Größe [128,128]
Bei generator und Diskriminator wird beim Trainieren jeweils Batchnormalization eingesetzt.

Als Zielfunktion wird wieder das W-GAN verwendet da es im Versuchsaufbau 1 die besseren Ergebnisse liefert.

4 Evaluation und Ergebnisse

Es wird nun in diesen Kapitel auf die Ergebnisse von Versuchsaufbau 1 und 2 eingegangen. Zunächst wird Versuchsaufbau 1 mit des Erlernen von latenten Raum von Punktwolken gezeigt. Anschließend geht es um die Ergebnisse von Versuchsaufbau 2 für die Rekonstruktion von zerstörten Blättern.

4.1 Ergebnisse - Versuchsaufbau 1

Die Ergebnisse von RAW-GAN mit den BlattDaten welches nach 500 Epochen Training lassen sich in Abb. entnehmen. Wie zu sehen ist sind die Blätter nicht gut genug für eine Weiterverarbeitung. Die Daten erinnern eher an einen hohlen Ball als an Blättern. Auch lässt der Trainingsverlauf aus Abb. zu entnehmen darauf schließen dass keine weitere Verbesserung möglich ist auch auf längere Epochen gesehen da es zu viele Sprünge in der Zielfunktion den Discriminator zu gut werden lässt und den Generator nicht verbessern lässt.

Ähnliche Ergebnisse sind auch mit den StuhlDaten zu beobachten in Abb. jeweils die Ergebnisse dafür. Es sind besser die Strukturen zu erkennen als bei den Blättern ebenfalls nicht optimale Ergebnisse. In Abb. der Trainingsverlauf.

Latent-GAN chair Latent-GAN leaf

4.2 Ergebnisse - Versuchsaufbau 2

Die Ergebnisse für das Latent-GAN mit den BlattDaten welches zunächst für 500 Epochs mit den Autoencoder trainiert wurde können Input und Output Paare aus Abbildung entnommen werden in Abbildung sind die Loss jeweils mit EMD-Loss und Wasser Distanz aufgelistet.




Abb. 25. Trainingsverlauf des RAW-GAN mit den Blatttdaten




Abb. 26. Trainingsverlauf des RAW-GAN mit den Blatttdaten




Abb. 27. Trainingsverlauf des RAW-GAN mit den Stuhl­daten mit 422 Trainingsdaten




Abb. 28. Trainingsverlauf des RAW-GAN mit den Stuhl­daten mit 422 Trainingsdaten




Abb. 29. Trainingsverlauf des RAW-GAN mit den Stuhlzeiten




Abb. 30. Trainingsverlauf des RAW-GAN mit den Stuhlzeiten




Abb. 31. Trainingsverlauf des Latent-GAN mit den Stuhldaten




Abb. 32. Trainingsverlauf des Latent-GAN mit den Stuhldaten




Abb. 33. Trainingsverlauf des Latent-GAN mit den Blatttdaten




Abb. 34. Trainingsverlauf des Latent-GAN mit den Blatttdaten

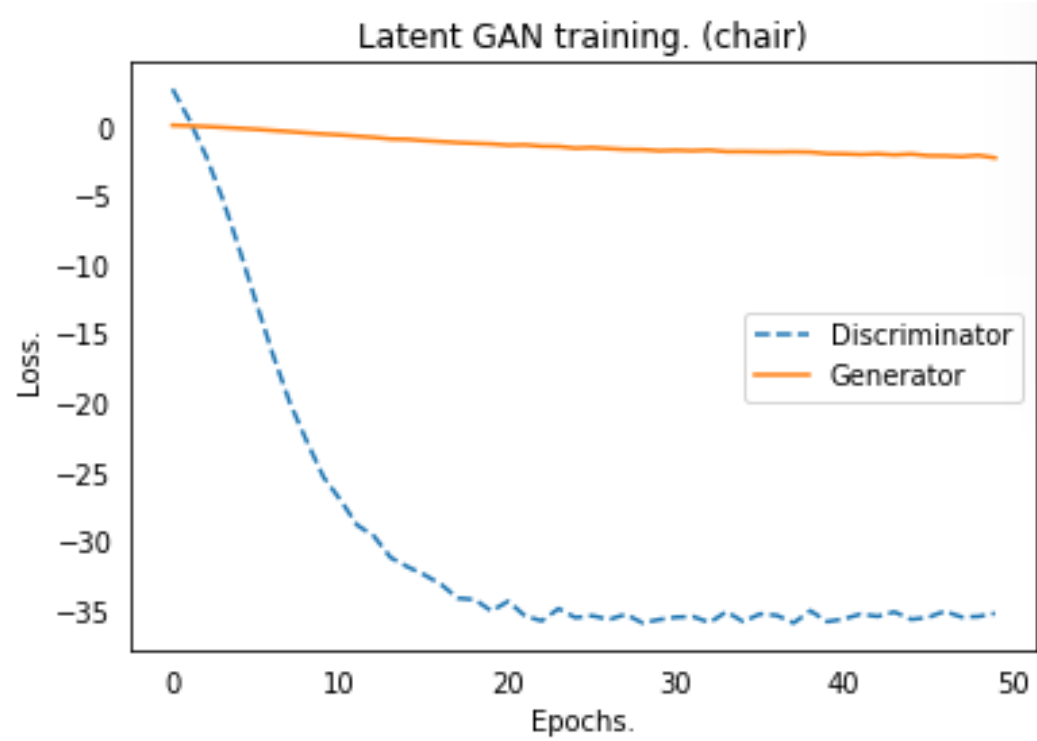


Abb. 35. Trainingsverlauf des Latent-GAN mit den Stuhldaten und 400 Trainingsdaten




Abb. 36. Trainingsverlauf des Latent-GAN mit den Stuhldaten und 400 Trainingsdaten

Die Ergebnisse für das Latent-GAN mit den Tischdaten welches zunächst für 500 Epochs mit den Autoencoder trainiert wurde können Input und Output Paare aus Abbildung entnommen werden in Abbildung sind die Loss jeweils mit EMD-Loss und Damfer Distanz aufgelistet.




Abb. 37. Trainingsverlauf des RAW-GAN mit den Blattdaten

5 Zusammenfassung und Diskussion

Ein GAN besteht aus zwei ANN, dem Discriminator und dem Generator. Das Ziel des G ist es Daten zu erzeugen, welche nicht von Trainingsdaten unterschieden werden können. Der Discriminator hat die Aufgabe zu unterscheiden ob der jeweilige Datensatz von G erzeugt wurde und somit ein fake Datensatz ist, oder von den Trainingsdaten stammt (Goodfellow et al., 2014). GANs werden derzeit noch erforscht. Es gibt noch einige offene Fragen, beispielsweise bezüglich der Performance hochauflösender Bilder (Wang et al., 2017). Es wurden in diesem




Abb. 38. Trainingsverlauf des Autoencoders mit den zerstörten Blattdaten CD Output




Abb. 39. Trainingsverlauf des Autoencoders mit den zerstörten Blattdaten CD input




Abb. 40. Trainingsverlauf des Autoencoders mit den zerstörten Blattdaten CD




Abb. 41. Trainingsverlauf des Autoencoders mit den zerstörten Blatttdaten EMD




Abb. 42. Trainingsbeispiele des Autoencoders mit den zerstörten Blatttdaten EMD

Paper einige Probleme, welche beim Trainieren von GAN auftreten können und mögliche Lösungsansätze, vorgestellt. Es gibt derzeit einige praktische Ansätze, welche in der Anwendung auf GANs zurück greifen. Beispielsweise durch Textbeschreibung eigene Bilder als Output generiert werden (Reed et al., 2016), oder 3D Daten erzeugt werden (Achlioptas et al., 2018). GANs finden Anwendung in unterschiedlichen Bereichen des Deep Learnings, da sie als Lösung des Problems angesehen werden, dass Neuronale Netzwerke eine hohe Menge an Trainingsdaten benötigen und GANs dieses Problem durch ihre Fähigkeit, neue Daten zu generieren, umgehen. GANs lernen eine Art "versteckte Repräsentation von Klassen, was dazu beitragen kann auch Modelle von komplexen Prozessen zu erlernen. Es gibt erste Ansätze bei denen im Reinforcement Learning durch GANs versucht wird Modelle von der Umwelt eines Agenten zu erlernen, welche dann auf Grundlage dieser Modelle Vorhersagen über zukünftige Ereignisse treffen kann (Pinto, Davidson, Sukthankar, & Gupta, 2017).

Abbildungsverzeichnis

1	Künstliches Neuronales Netzwerk	5
2	künstliches Neuron	6
3	Sigmoid Funktion	7
4	LossFunktion	9
5	Minimum Maximum Saddle Point	9
6	aaaa	12
7	Polygon File Format	13
8	Punktwolke eines Tabakblattes	13
9	Scankopf	14
10	Convolutional Neural Network	16
11	Convolution Beispiel	17
12	Deconvolution Beispiel	17
13	Autoencoder	19
14	Earth Mover Distance	20
15	Chamfer Distance	20
16	Generativ Adverserial Network	21
17	Deep Convolutional GAN	23
18	KL Divergenz und JS Divergenz	23
19	Conditional Adverserial Network	27
20	Latent-GAN	28
21	Bild Rekonstruktion eines Hundes welches durch ein Artefakt zerstört wurde	29
22	3D Punktwolke einer Tabakpflanze	30
23	3D Punktwolke einer Tabakpflanze	31
24	3D Punktwolke einer Tabakpflanze	32
25	Trainingsverlauf des RAW-GAN mit den Blattdaten	34
26	Trainingsverlauf des RAW-GAN mit den Blattdaten	34
27	Trainingsverlauf des RAW-GAN mit den Stuhlzeiten mit 422 Trainingsdaten	35
28	Trainingsverlauf des RAW-GAN mit den Stuhlzeiten mit 422 Trainingsdaten	35
29	Trainingsverlauf des RAW-GAN mit den Stuhlzeiten	36
30	Trainingsverlauf des RAW-GAN mit den Stuhlzeiten	36
31	Trainingsverlauf des Latent-GAN mit den Stuhlzeiten	37
32	Trainingsverlauf des Latent-GAN mit den Stuhlzeiten	37
33	Trainingsverlauf des Latent-GAN mit den Blattdaten	38
34	Trainingsverlauf des Latent-GAN mit den Blattdaten	38
35	Trainingsverlauf des Latent-GAN mit den Stuhlzeiten und 400 Trainingsdaten	39
36	Trainingsverlauf des Latent-GAN mit den Stuhlzeiten und 400 Trainingsdaten	39
37	Trainingsverlauf des RAW-GAN mit den Blattdaten	40
38	Trainingsverlauf des Autoencoders mit den zerstörten Blattzeiten CD Output	41

39	Trainingsverlauf des Autoencoders mit den zerstörten Blattdaten	
	CD input	41
40	Trainingsverlauf des Autoencoders mit den zerstörten Blattdaten CD .	42
41	Trainingsverlauf des Autoencoders mit den zerstörten Blattdaten EMD	43
42	Trainingsbeispiele des Autoencoders mit den zerstörten Blattdaten	
	EMD	43

Tabellenverzeichnis

Literatur

- Achlioptas, P., Diamanti, O., Mitliagkas, I., & Guibas, L. (2018). Learning representations and generative models for 3d point clouds.
- Ahmed, E., Saint, A., Shabayek, A. E. R., Cherenkova, K., Das, R., Gusev, G., ... Ottersten, B. (2018). Deep learning advances on different 3d data representations: A survey. *arXiv preprint arXiv:1808.01462*.
- Arjovsky, M., Chintala, S., & Bottou, L. (2017). Wasserstein gan. *arXiv preprint arXiv:1701.07875*.
- Dong, C., Loy, C. C., He, K., & Tang, X. (2016a). Image super-resolution using deep convolutional networks. , *38*(2), 295–307.
- Dong, C., Loy, C. C., He, K., & Tang, X. (2016b). Image super-resolution using deep convolutional networks. *IEEE transactions on pattern analysis and machine intelligence*, *38*(2), 295–307.
- Dumoulin, V., & Visin, F. (2016). A guide to convolution arithmetic for deep learning. *arXiv preprint arXiv:1603.07285*.
- Fan, H., Su, H., & Guibas, L. (2017). A point set generation network for 3d object reconstruction from a single image. In *2017 IEEE conference on computer vision and pattern recognition (cvpr)* (pp. 2463–2471).
- Golik, P., Doetsch, P., & Ney, H. (2013). Cross-entropy vs. squared error training: a theoretical and experimental comparison. In *Interspeech* (Vol. 13, pp. 1756–1760).
- Goodfellow, I., Bengio, Y., Courville, A., & Bengio, Y. (2016). *Deep learning* (Vol. 1). MIT press Cambridge.
- Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., ... Bengio, Y. (2014). Generative adversarial nets. In *Advances in neural information processing systems* (pp. 2672–2680).
- Halevy, A., Norvig, P., & Pereira, F. (2009). The unreasonable effectiveness of data. *IEEE Intelligent Systems*, *24*(2), 8–12.
- Hinton, G. E., & Salakhutdinov, R. R. (2006). Reducing the dimensionality of data with neural networks. *science*, *313*(5786), 504–507.
- Huang, G., Yuan, Y., Xu, Q., Guo, C., Sun, Y., Wu, F., & Weinberger, K. (2018). *An empirical study on evaluation metrics of generative adversarial networks*. Retrieved from <https://openreview.net/forum?id=Sy1f0e-R>
-
- Huszár, F. (2015). How (not) to train your generative model: Scheduled sampling, likelihood, adversary? *arXiv preprint arXiv:1511.05101*.
- Ioffe, S., & Szegedy, C. (2015). Batch normalization: Accelerating deep network training by reducing internal covariate shift. *arXiv preprint arXiv:1502.03167*.
- Liu, G., Reda, F. A., Shih, K. J., Wang, T.-C., Tao, A., & Catanzaro, B. (2018). Image inpainting for irregular holes using partial convolutions. *arXiv preprint arXiv:1804.07723*.
- Ng, A. Y., & Jordan, M. I. (2002). On discriminative vs. generative classifiers: A comparison of logistic regression and naive bayes. In *Advances in neural information processing systems* (pp. 841–848).

- Pinto, L., Davidson, J., Sukthankar, R., & Gupta, A. (2017). Robust adversarial reinforcement learning. *arXiv preprint arXiv:1703.02702*.
- Radford, A., Metz, L., & Chintala, S. (2015). Unsupervised representation learning with deep convolutional generative adversarial networks. *arXiv preprint arXiv:1511.06434*.
- Ravanbakhsh, S., Schneider, J., & Póczos, B. (2016). Deep learning with sets and point clouds. *arXiv preprint arXiv:1611.04500*.
- Reed, S., Akata, Z., Yan, X., Logeswaran, L., Schiele, B., & Lee, H. (2016). Generative adversarial text to image synthesis. *arXiv preprint arXiv:1605.05396*.
- Salimans, T., Goodfellow, I., Zaremba, W., Cheung, V., Radford, A., & Chen, X. (2016). Improved techniques for training gans. In *Advances in neural information processing systems* (pp. 2234–2242).
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: a simple way to prevent neural networks from overfitting. *The Journal of Machine Learning Research*, 15(1), 1929–1958.
- Sutskever, I., Martens, J., Dahl, G., & Hinton, G. (2013). On the importance of initialization and momentum in deep learning. In *International conference on machine learning* (pp. 1139–1147).
- Wang, T.-C., Liu, M.-Y., Zhu, J.-Y., Tao, A., Kautz, J., & Catanzaro, B. (2017). High-resolution image synthesis and semantic manipulation with conditional gans. *arXiv preprint arXiv:1711.11585*.
- Wu, J., Zhang, C., Xue, T., Freeman, B., & Tenenbaum, J. (2016). Learning a probabilistic latent space of object shapes via 3d generative-adversarial modeling. In *Advances in neural information processing systems* (pp. 82–90).
- Yi, L., Shao, L., Savva, M., Huang, H., Zhou, Y., Wang, Q., ... others (2017). Large-scale 3d shape reconstruction and segmentation from shapenet core55. *arXiv preprint arXiv:1710.06104*.